

UNIVERSIDAD NACIONAL TECNOLÓGICA DE LIMA SUR

**FACULTAD DE INGENIERÍA Y GESTIÓN
ESCUELA PROFESIONAL DE SISTEMAS**



**Diseño de un Sistema Conversacional Inteligente con Técnicas de
Nature Language Process para el Acompañamiento Psicológico de
Estudiantes Universitarios con Síntomas de Depresión**

PLAN DE TESIS

PRESENTADO POR:

CABALLERO VILLAZANA, DIEGO JEREMY

ORCID:

FERNANDEZ HUAMAN, ANDRE RAFAEL

ORCID:

ASESOR:

SANCHEZ GARCES JORGE ALEJANDRO

ORCID:

Villa el Salvador - Perú

2025

CAPÍTULO I:

1.1 MOTIVACIÓN

La salud mental se ha convertido en una preocupación creciente, especialmente en estudiantes universitarios que enfrentan presiones académicas, sociales y económicas. En el Perú persisten grandes brechas en la atención psicológica: los recursos son limitados, los tiempos de espera prolongados y las alternativas insuficientes. Según el Ministerio de Salud del Perú (2024), «establecimientos del Minsa atendieron más de 250 000 casos de depresión a lo largo del año 2024»; el propio Ministerio de Salud del Perú (2024) también informó que «el Minsa atendió 280 917 casos de depresión durante el año 2023». En el ámbito universitario, Méndez Sánchez (2025), en la Universidad Nacional Federico Villarreal, reportó que «el 59 % presentó depresión leve y el 17 % moderada» en estudiantes de medicina. Finalmente, Diario Correo (2024) consignó que «se registraron 756 casos de depresión grave en la población juvenil durante 2024»; si bien esta última cifra no corresponde exclusivamente a universitarios, refuerza la urgencia de soluciones complementarias y accesibles de apoyo psicológico para estudiantes.

Ante este escenario, esta investigación propone el desarrollo de un sistema experto conversacional como alternativa de apoyo emocional. Este sistema ofrecerá acompañamiento psicológico continuo, disponible las veinticuatro horas del día, los siete días de la semana, utilizando inteligencia artificial y aprendizaje automático para detectar señales de riesgo y brindar recomendaciones personalizadas. Su principal innovación radica en su capacidad adaptativa: aprende de cada interacción, ajustándose al perfil emocional del estudiante para mejorar tanto su experiencia como la de futuros usuarios. Así, se busca empoderar al estudiante en la gestión de su salud mental, facilitar el acceso a orientación inmediata y contribuir a una atención preventiva, inteligente y sostenible dentro del entorno universitario.

1.2 ESTADO DEL ARTE

Nature Language Process (NLP)

El uso de algoritmos de NLP (Nature Language Process) se ha orientado al reconocimiento de emociones y estados psicológicos a través de interacciones conversacionales. Por ejemplo, Elahimanesh et al. (2023) desarrollaron un chatbot en el idioma farsi basado en técnicas de clasificación semántica y de sentimientos, alcanzando una precisión superior al 92 % en la identificación de categorías emocionales, lo que evidencia el potencial del NLP para apoyar intervenciones en salud mental.

Según Denecke et al. (2025), los chatbots aún presentan limitaciones para interpretar expresiones ambiguas o coloquiales; en estos casos, el contexto resulta decisivo para distinguir una simple broma de una posible señal de riesgo psicológico, lo que evidencia la necesidad de mejorar los modelos de NLP en su capacidad de comprensión contextual.

La mayor parte de los usuarios utilizan palabras ajenas al diccionario, lenguajes coloquial nacional (jergas), reto para la tecnología, uso de diccionarios coloquiales

Evaluaciones Psicométricas Digitales

Por otro lado, los modelos de NLP aplicados a la atención de pacientes con trastornos mentales mediante chatbots pueden potenciarse incorporando pruebas psicométricas como el PHQ-9 y el GAD-7, dado que son instrumentos gratuitos y de libre uso. Según Pfizer, al anunciar el acceso público gratuito a estas escalas, puso “a disposición” los cuestionarios para apoyar la evaluación y diagnóstico sin restricciones de copyright ni costo (Pfizer, 2010). Además, en los formularios oficiales se consigna expresamente que “No permission required to reproduce, translate, display or distribute” para el PHQ-9 (American Psychological Association, s. f.) y para el GAD-7 (Didi Hirsch Mental Health Services, s. f.). Organizaciones de referencia confirman el carácter free to use del GAD-7 y remiten a los términos de PHQ Screeners de Pfizer (CORC, s. f.). En este marco, Prankeviciene et al. (2022) validaron dichas escalas en estudiantes

universitarios de Lituania, reportando α de Cronbach = 0.86 (PHQ-9) y 0.91 (GAD-7), lo que respalda su robustez psicométrica en población universitaria.

estipular pagina que menciona el acceso libre
arquitectura para preguntas personalizadas

Según Zhang (2020), una de las principales limitaciones de las implementaciones digitales es que suelen presentar las mismas preguntas de forma estandarizada a todos los usuarios, lo que reduce la adaptabilidad y el nivel de compromiso en jóvenes universitarios.

Chatbots Conversacionales en Salud Mental

En el trabajo presentado por Klos et al. (2021) evaluaron la viabilidad de Tess, un chatbot basado en inteligencia artificial aplicado a estudiantes universitarios de Argentina. El sistema fue bien aceptado por los participantes y se asoció con una disminución significativa de los síntomas de ansiedad, aunque no mostró cambios relevantes en depresión, lo que evidencia un potencial positivo en el bienestar emocional.

A pesar de estos avances, aún se identifican dificultades en la personalización: muchos chatbots trabajan con guiones predefinidos que limitan la naturalidad de la conversación y la capacidad de adaptación a las necesidades individuales del usuario (Haque & Rubya, 2023).

1.3. DESCRIPCIÓN DEL PROBLEMA

La depresión es una enfermedad social global que afecta a millones de personas en todo el mundo, siendo reconocida por la Organización Mundial de la Salud (OMS) como la principal causa de discapacidad. Según la OMS (2023), «aproximadamente 280 millones de personas padecen de depresión a nivel mundial, lo que representa el 4,0% de la población global» (Organización Mundial de la Salud, 2023). Además, en el contexto de la pandemia de COVID-19, la OMS reportó un aumento del 25% en los casos de depresión a nivel mundial en el primer año de la crisis sanitaria (WHO, 2022), lo que resalta la gravedad de la situación.

En Perú, la tasa de prevalencia de la depresión también ha mostrado un aumento alarmante. Durante el año 2023, el Ministerio de Salud de Perú reportó que se atendieron 280,917 casos de depresión, lo que representa un aumento del 22% respecto a 2022, cuando se registraron 256,563 casos (Ministerio de Salud del Perú, 2024). Este incremento refleja un crecimiento sostenido de los casos atendidos por trastornos depresivos en la población peruana, lo que demanda una mayor atención a las estrategias de intervención en salud mental.

En el ámbito universitario, la depresión ha emergido como un problema significativo. Según un estudio realizado por Paricahua y Peralta (2024), el 42,7% de los estudiantes en la ciudad de Puerto Maldonado, Perú, presentaron síntomas de depresión. Esta cifra subraya la creciente prevalencia de la depresión en jóvenes universitarios, quienes atraviesan una etapa clave de su desarrollo académico y emocional.

El aumento en la prevalencia de la depresión, ansiedad y estrés en los estudiantes universitarios refleja la necesidad urgente de mejorar las estrategias de apoyo y detección temprana en las instituciones educativas. Las presiones académicas y los cambios de vida típicos de esta etapa pueden contribuir significativamente a la aparición y agravamiento de estos trastornos.

En este contexto, las herramientas tecnológicas de salud mental han emergido como una alternativa de bajo costo y accesible para el tratamiento y apoyo psicológico. Sin embargo, a pesar de sus beneficios, presentan importantes limitaciones. Según Denecke et al. (2025), la mayoría de los chatbots actuales no logran ofrecer respuestas completamente personalizadas, lo que limita su efectividad en el tratamiento de trastornos complejos como la depresión. Además, estos sistemas no cuentan con un adecuado mecanismo de seguimiento y monitoreo clínico, lo que impide una atención continua y precisa para los usuarios.

Herramienta por chat bot

Interactividad básica, mecánica.

ser propositivo:

1.4 FORMULACIÓN DEL PROBLEMA

1.4.1 Formulación del problema general

La depresión en estudiantes universitarios es una preocupación creciente, especialmente en el contexto peruano, donde los recursos para la atención psicológica son limitados, y los tiempos de espera en los servicios de salud son largos. Frente a este panorama, surge la necesidad de desarrollar un sistema experto conversacional basado en técnicas de Natural Language Processing (NLP) que permita proporcionar acompañamiento psicológico continuo y accesible para los estudiantes universitarios con síntomas de depresión. Este sistema tiene como objetivo la detección temprana de señales de riesgo, la oferta de recomendaciones personalizadas y el empoderamiento de los estudiantes en la gestión de su salud mental, todo ello mediante el uso de inteligencia artificial y aprendizaje automático.

1.4.2 Formulación de los problemas específicos

1. El diseño de una base de conocimiento adecuada que permita al sistema experto conversacional ofrecer respuestas personalizadas y efectivas, considerando las características emocionales y lingüísticas de los estudiantes universitarios con síntomas de depresión.
2. La creación de una arquitectura del sistema que permita al sistema experto conversacional interactuar de manera fluida y natural con los usuarios, garantizando que sea capaz de detectar señales de riesgo y proporcionar un acompañamiento adecuado en tiempo real.
3. La validación del funcionamiento del sistema a través de pruebas controladas que permitan evaluar su capacidad de interacción, precisión en la detección de señales de riesgo y su utilidad percibida por los usuarios, garantizando la efectividad del acompañamiento psicológico ofrecido.

Diseño de un Sistema Experto Conversacional con Técnicas de NLP para el Acompañamiento Psicológico de Estudiantes Universitarios con Síntomas de Depresión

Pregunta general: ¿En qué medida el diseño de un Sistema Experto Conversacional con Técnicas de Natural Language Process permite el acompañamiento Psicológico de Estudiantes Universitarios con Síntomas de Depresión?

Preguntas específicas:

¿En qué medida la base de conocimiento y los diccionarios logran un buen Sistema Experto Conversacional con Técnicas de Natural Language Process para el acompañamiento Psicológico de Estudiantes Universitarios con Síntomas de Depresión?

¿En qué medida la arquitectura logran un buen Sistema Experto Conversacional con Técnicas de Natural Language Process para el acompañamiento Psicológico de Estudiantes Universitarios con Síntomas de Depresión?

¿Cómo la validación y el funcionamiento del sistema mediante pruebas controladas, logran una capacidad de interacción, precisión en la detección de señales de riesgo y utilidad percibida por los usuarios?

1.5. DEFINICIÓN DE LOS OBJETIVOS

Objetivo general

Diseñar un sistema conversacional inteligente con técnicas de Nature Language Process (NLP) que permita detectar señales de riesgo emocional y brindar acompañamiento psicológico preliminar a estudiantes universitarios con síntomas de depresión.

Objetivos específicos

Analizar los síntomas depresivos más comunes en estudiantes universitarios y su expresión en lenguaje natural, mediante revisión bibliográfica y estudios clínicos validados.

Construir una base de conocimiento y reglas de inferencia para el sistema experto, considerando criterios clínicos y escalas psicométricas como el PHQ-9.

Diseñar un modelo de procesamiento de lenguaje natural (NLP) capaz de interpretar el lenguaje coloquial de los estudiantes y extraer indicadores emocionales relevantes.

Desarrollar la arquitectura del sistema experto conversacional, integrando el módulo de NLP con el motor de inferencia y la interfaz conversacional.

Validar el funcionamiento del sistema mediante pruebas controladas, evaluando su capacidad de interacción, precisión en la detección de señales de riesgo y utilidad percibida por los usuarios.

1.6 JUSTIFICACIÓN DE LA INVESTIGACIÓN

La presente investigación tiene como producto final el diseño de una arquitectura de procesamiento de lenguaje natural conversacional, cuyo propósito es facilitar la detección temprana de señales de riesgo emocional y brindar acompañamiento psicológico preliminar a estudiantes universitarios con síntomas de depresión. Esta propuesta responde a la creciente demanda de atención en salud mental en el entorno universitario, donde los recursos profesionales son limitados y los tiempos de espera suelen ser prolongados(sustentar) porque hay una mayor cantidad de pacientes y pocos profesionales. Al integrar técnicas de procesamiento de lenguaje natural (NLP) e inteligencia artificial, se busca interpretar expresiones emocionales,incluyendo jergas y lenguaje coloquial, y proporcionar respuestas adaptadas al perfil emocional de cada usuario.

Para lograr este objetivo, se desarrollará una **arquitectura modular (SLM)**, capaz de combinar una base de conocimiento especializada, diccionarios lingüísticos personalizados y un motor de inferencia basado en reglas psicométricas validadas como el PHQ-9. Este enfoque permitirá una interacción empática, continua y disponible las 24 horas, reduciendo las barreras de acceso a orientación psicológica y fortaleciendo estrategias de prevención. Asimismo, la capacidad de adaptación del sistema representa una innovación clave, al ofrecer acompañamiento inteligente, personalizado y escalable en contextos de alta demanda y limitada cobertura profesional.

highlight: arquitectura modular SLM
SMALL LANGUAGE MODEL

2.1. ANTECEDENTES

¿QUÉ HIZO?

¿CÓMO LO HIZO?

SU RESULTADO PREVALENTE (UNO)

Kang y Hong (2025), esta investigación desarrolló y evaluó un chatbot de salud mental denominado HoMemeTown Dr. CareSam, utilizando el modelo ChatGPT 4.0 para ofrecer soporte emocional y detección de riesgos en jóvenes adultos. Utilizando procesamiento de lenguaje natural (NLP), el chatbot demostró un alto desempeño en la clasificación emocional, alcanzando una precisión del 88.9% en el análisis de sentimientos, con el modelo multimodal mostrando un 82.6% de precisión en la detección de riesgos.

En un estudio piloto realizado en Argentina, Klos et al. (2021) evaluaron la viabilidad y aceptabilidad de Tess, un chatbot basado en inteligencia artificial, para tratar la ansiedad y

la depresión en estudiantes universitarios. El grupo experimental utilizó Tess durante 8 semanas, mientras que el grupo control recibió un libro electrónico sobre psicoeducación para la depresión. A pesar de que no se encontraron diferencias significativas entre ambos grupos en cuanto a los síntomas de depresión y ansiedad, el grupo experimental mostró una disminución significativa en los síntomas de ansiedad.

Según Liu et al. (2022), el estudio evaluó la efectividad de un chatbot terapéutico de autoayuda para depresión en universitarios comparado con biblioterapia; para ello realizaron un ensayo controlado aleatorizado con ochenta y tres estudiantes durante dieciséis semanas, usando como medidas PHQ-9 y GAD-7, con el chatbot "XiaoNan" desplegado en WeChat y seguimiento cada cuatro semanas. El resultado fue que el grupo con chatbot mostró una reducción significativa de la depresión frente a biblioterapia (PHQ-9: $F = 22.89$; $p < 0.01$; $d = 0.83$).

Yokotani et al. (2025) evaluaron un chatbot basado en el Protocolo Unificado (UP) para trastornos emocionales en estudiantes universitarios japoneses, implementándolo en un ensayo controlado aleatorizado con cuatro condiciones (solo chatbot, solo guía UP, combinación de ambos y lista de espera) durante ocho semanas de intervención y cuatro de seguimiento; midieron cambios con OASIS (ansiedad) y ODSIS (depresión) y analizaron las expresiones emocionales mediante análisis de sentimientos; el resultado fue que el grupo solo chatbot mostró una reducción significativa de la ansiedad que se mantuvo en el seguimiento, con un mecanismo sugerido de mayor expresión de emociones negativas (tristeza) que facilitó la aceptación emocional y el alivio ansioso.

Anmella et al. (2023) desarrollaron y evaluaron Vickybot, un chatbot para tamizaje, monitoreo e intervención breve en síntomas ansioso-depresivos y burnout; el proceso incluyó pruebas técnicas con cuarenta controles sanos, simulaciones clínicas para ajustar personalización y detección de riesgo suicida (con módulos basados en PHQ-9, GAD-7, psicoeducación, CBT, mindfulness, ACT y DBT), y un estudio de factibilidad y potencial efectividad de un mes con treinta y cuatro participantes de atención primaria y personal de salud, con mediciones repetidas cada dos semanas; el resultado fue una disminución significativa del burnout laboral a las dos semanas, sin cambios significativos en ansiedad o depresión.

Guerrero et al. (2023) desarrollaron una herramienta basada en Internet para la identificación de la ansiedad en estudiantes universitarios mediante el análisis de emociones en texto y en expresiones faciales. Utilizaron dos métodos de predicción de ansiedad: uno basado en el análisis de las emociones expresadas en las publicaciones de los estudiantes en Facebook, y otro basado en el reconocimiento facial durante una prueba de habilidades técnicas. Ambos métodos fueron validados utilizando la escala AMAS-C, un test reconocido para medir la ansiedad en adultos jóvenes. Los resultados mostraron que el análisis de texto presentó una ligera ventaja en términos de precisión (86.84 %) en la predicción de la ansiedad en comparación con el análisis facial (84.21 %).

Villarreal et al. (2024) realizaron una revisión sistemática y meta-análisis para evaluar la efectividad de las intervenciones autoadministradas basadas en modelos de procesamiento de lenguaje natural (NLP) para reducir los síntomas de depresión y ansiedad. La

investigación incluyó 21 estudios, de los cuales 16 fueron utilizados en el meta-análisis. Los resultados mostraron que las intervenciones basadas en NLP fueron significativamente más efectivas para reducir los síntomas depresivos (SMD 0.819) y de ansiedad (SMD 0.272) en comparación con diversos controles, como listas de espera o intervenciones psicoeducativas.

Goyal et al. (2025), la investigación propuso un sistema de evaluación de salud mental basado en IA denominado MindLift, dirigido a estudiantes. Utilizando técnicas avanzadas como redes neuronales convolucionales (CNN), redes neuronales recurrentes (RNN), y procesamiento de lenguaje natural (NLP), MindLift integra múltiples modalidades de datos, tales como expresiones faciales, tono de voz y análisis de sentimientos de textos, para proporcionar un análisis emocional integral. El sistema también incluye un chatbot inteligente que ofrece intervenciones personalizadas basadas en la Terapia Cognitivo-Conductual (CBT). El resultado prevalente de este estudio mostró que MindLift logró un alto desempeño en la clasificación emocional, con una precisión que varió entre el 78.5% y el 88.9% dependiendo de la modalidad, destacándose el modelo multimodal con un 91.3% de precisión en la fusión de datos

Chen et al. (2025), la investigación comparó la efectividad de un AI chatbot con una línea de atención telefónica de enfermería en la reducción de los niveles de ansiedad y depresión en la población general; utilizando técnicas de procesamiento de lenguaje natural (NLP) para interpretar y generar respuestas a las consultas de los usuarios. El chatbot fue implementado en un ensayo controlado aleatorizado, logrando una reducción significativa en los puntajes de depresión y ansiedad en el grupo del chatbot (pre: 5.13, post: 3.68 en PHQ-9, $p=0.008$; pre: 4.74, post: 3.40 en GAD-7, $p=0.005$), mostrando un desempeño comparable al de la línea telefónica de enfermería

2. BASES TEÓRICAS

2.1 Depresión Universitaria

2.1.1 Prevalencia de la Depresión Universitaria

La prevalencia de los trastornos mentales entre los estudiantes universitarios ha sido un tema de preocupación, especialmente en carreras demandantes como la medicina. En un estudio realizado en universidades de Lambayeque, Perú, se encontró que el 61.8% de los estudiantes presentaban síntomas de ansiedad y un 22.0% de depresión. Además, factores como el tipo de universidad, el sexo y la actividad física se asociaron significativamente con la presencia de estos trastornos. (Piscoya et al., 2023).

Un estudio realizado en 2021 entre estudiantes de medicina en Perú durante la segunda ola de la pandemia de COVID-19 reveló una alta prevalencia de síntomas depresivos, ansiosos y de estrés, con 71.6% de los participantes presentando síntomas depresivos, 71.9% síntomas de ansiedad y 62.7% síntomas de estrés. Estos trastornos fueron significativamente más frecuentes entre los estudiantes que no realizaban ejercicio físico de manera regular y aquellos con trastornos de conducta alimentaria (Valladares et al., 2023).

2.1.2 Impacto de la Depresión Universitaria

La depresión tiene un impacto significativo en el rendimiento académico de los estudiantes universitarios, particularmente durante crisis de salud pública como la pandemia de COVID-19. En un estudio realizado entre estudiantes universitarios, se observó que la depresión afecta negativamente el compromiso académico, con un mediador importante en este proceso siendo el sentido de seguridad de los estudiantes. Además, el impacto psicológico de la pandemia desempeñó un papel moderador en la relación entre depresión y compromiso académico. Los estudiantes que experimentaron altos niveles de inseguridad, debido en parte a la pandemia, mostraron un menor nivel de compromiso con sus estudios, lo que destaca la necesidad urgente de intervenciones psicológicas para mitigar estos efectos (Tang & He, 2023).

La relación entre los síntomas de depresión y el rendimiento académico en estudiantes universitarios ha sido ampliamente estudiada, encontrando que los síntomas de depresión son predictores significativos del retraso en el progreso académico. En un estudio realizado en una universidad sudafricana, se observó que los estudiantes con síntomas de depresión moderados y graves tenían una mayor probabilidad de experimentar retrasos en su progresión académica. Los estudiantes con síntomas de depresión grave tuvieron casi tres veces más probabilidades de enfrentar este tipo de retraso en comparación con aquellos sin síntomas depresivos significativos. Este hallazgo subraya la importancia de abordar la salud mental de los estudiantes, ya que los trastornos depresivos pueden afectar directamente su capacidad para cumplir con los requisitos académicos (Wagner et al., 2022).

2.1.3 Instrumentos usados para el diagnóstico

A) Cuestionario de la salud del paciente (PHQ-9)

El PHQ-9 (Patient Health Questionnaire-9) es una herramienta ampliamente utilizada para la evaluación de síntomas depresivos. Consiste en un cuestionario autoadministrado que consta de nueve ítems, los cuales miden la frecuencia de síntomas típicos de la depresión, como la tristeza, la fatiga y los pensamientos suicidas, durante las últimas dos semanas. Los resultados del PHQ-9 se obtienen mediante una escala Likert de cuatro puntos, y la puntuación total varía de 0 a 27, lo que permite clasificar los niveles de gravedad de la depresión. En un estudio realizado en estudiantes universitarios de Bangladesh, se validó la fiabilidad del PHQ-9 mediante análisis factorial confirmatorio, demostrando su consistencia interna y validez convergente al correlacionarse fuertemente con otras herramientas de medición de ansiedad y depresión, como el GAD-7 (Rahman et al., 2022). Cabe señalar que los derechos de autor y la distribución oficial del PHQ-9 pertenecen a Pfizer Inc., la cual ofrece acceso público y gratuito a sus instrumentos de evaluación de salud mental con el propósito de mejorar el diagnóstico y la atención de los pacientes (Pfizer, 2022).

B) Beck Depression Inventory-II (BDI-II)

El Beck Depression Inventory-II (BDI-II) es un cuestionario de autoinforme compuesto por 21 ítems, diseñado para medir la gravedad de los síntomas depresivos en las últimas dos semanas, conforme a los criterios diagnósticos del DSM-IV. Cada ítem se puntúa en una escala de 0 a 3, evaluando síntomas tanto cognitivos-afectivos, como tristeza, culpa o desesperanza, así como somáticos-vegetativos como, fatiga, alteraciones del sueño o del apetito,. Esta versión actualizada sustituyó ítems del BDI-IA menos sensibles, como pérdida de peso o distorsión de la imagen corporal, por otros que reflejan mejor la intensidad de la depresión, tales como agitación, sentimientos de inutilidad, dificultad para concentrarse y pérdida de energía (Wang & Gorenstein, 2013). Cabe señalar que el BDI-II es de uso gratuito, y su acceso público está disponible a través del portal del Luria Neuroscience Institute, que ofrece la herramienta en línea para fines educativos y de investigación (Luria Neuroscience Institute, s.f.).

C) Center for Epidemiologic Studies Depression Scale (CES-D)

El Center for Epidemiologic Studies Depression Scale (CES-D) es un cuestionario de autoinforme compuesto por 20 ítems, desarrollado por el *National Institute of Mental Health* para evaluar la presencia y gravedad de los síntomas depresivos en población general. Cada ítem se califica en una escala Likert de cuatro puntos (de 0 = “rara vez o nunca” a 3 = “la mayor parte del tiempo”), valorando la frecuencia con que el individuo ha experimentado síntomas durante la última semana. El instrumento evalúa

cuatro dimensiones principales: afecto depresivo, afecto positivo (invertido), síntomas somáticos y dificultades interpersonales (Radloff, 1977). Cabe destacar que el CES-D es de uso gratuito y está disponible públicamente a través del portal oficial *CESD-R.com*, el cual proporciona acceso libre a la escala para fines educativos, clínicos y de investigación (CESD-R, s.f.).

Tabla 1: Comparación de instrumentos para la evaluación de síntomas depresivos

Criterio	PHQ-9	BDI-II	CES-D
Precisión diagnóstica	Alta; se basa en criterios DSM-IV/DSM-V.	Muy alta; validado clínicamente para diagnóstico de depresión.	Buena; útil para detección, pero no diagnóstico clínico.
Longitud y facilidad de uso	Muy breve (9 ítems); fácil de administrar y puntuar.	Más extenso (21 ítems); mayor carga cognitiva para el usuario.	Moderado (20 ítems); sencillo pero más largo que el PHQ-9.
Adecuación para entornos digitales / chatbots	Excelente; preguntas cortas y formato claro, ideal para NLP.	Limitada; ítems largos y más complejos semánticamente .	Buena; aunque más ítems, las respuestas son simples.
Uso en población universitaria	Amplia evidencia empírica y validaciones recientes.	Usado en contextos clínicos y de investigación avanzada.	Usado principalmente en estudios epidemiológicos y poblacionales.
Propiedad y acceso	Gratuito (Pfizer).	Gratuito (Luria Neuroscience Institute).	Gratuito (CESD-R.).
Tiempo promedio de aplicación	3–5 minutos.	8–10 minutos.	7–9 minutos.

Entre los tres instrumentos analizados, el PHQ-9 se considera el más adecuado para el presente estudio, ya que combina brevedad, validez psicométrica y compatibilidad tecnológica. Su estructura simple y validación en contextos universitarios lo convierten en la herramienta óptima para integrarse en un sistema experto conversacional que emplee técnicas de procesamiento de lenguaje natural (NLP) orientado al acompañamiento psicológico preventivo.

2.2 Uso de Chatbots y Sistemas Expertos Conversacionales en Salud Mental

2.2.1 Chatbots en Salud Mental

El chatbot es un software diseñado para interactuar mediante texto, chats o voz. También denominados talkbot, bot o agente interactivo, estos sistemas se emplean en plataformas de diálogo con diversos propósitos prácticos, como la atención al cliente. (Pionce Arteaga et al., 2022)

Un chatbot es una aplicación de software permite simular una conversación con una persona, su facilidad con la que los chatbots pueden incorporarse en cualquier sector debido a su disponibilidad y fácil usabilidad, es diseñada, para que simule una conversación con una persona como si estuviera conversando con otro ser humano, por medio del procesamiento de lenguaje natural. (Gómez Lorente, 2020)

El funcionamiento de un chatbot comienza cuando el usuario interactúa con él mediante texto o voz, ya sea a través de una aplicación de mensajería, un sitio web o un dispositivo compatible. Luego, el asistente virtual procesa el mensaje o comando utilizando técnicas de procesamiento de lenguaje natural (PLN), lo que le permite interpretar y comprender el significado detrás de las palabras. Basándose en la entrada del usuario, el chatbot accede a su base de datos, aplica reglas predefinidas o emplea inteligencia artificial para generar una respuesta adecuada. Los sistemas más avanzados ofrecen respuestas más personalizadas y contextualizadas. Además, pueden mantener conversaciones dinámicas, adaptándose a nuevas preguntas y proporcionando servicios adicionales según sea necesario. (Gómez Lorente, 2020)

2.2.2 Estructura de un Chatbot

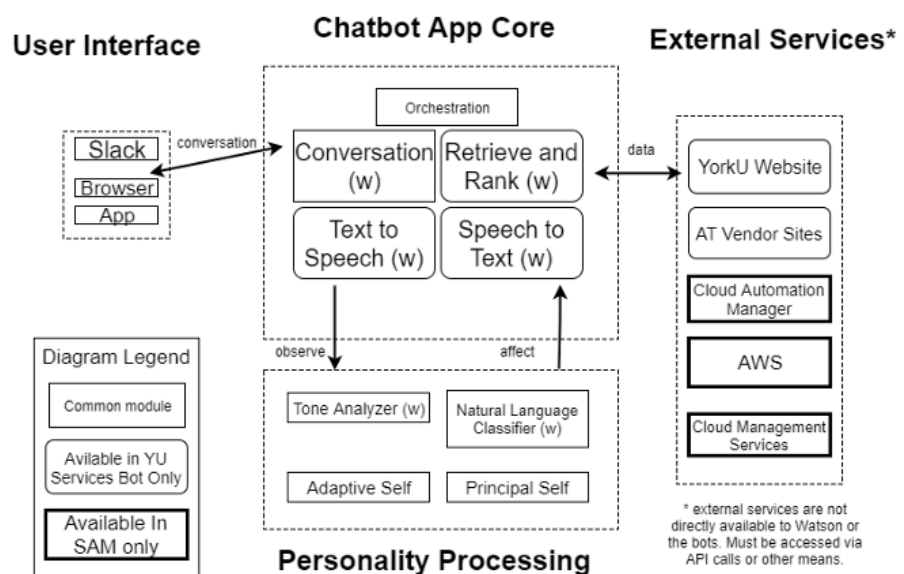
A) Interfaz de Usuario: Cada chatbot puede tener una interfaz de usuario (UI) personalizada, que debe adaptarse a las necesidades del dominio objetivo. Herramientas como Node-RED permiten cambiar fácilmente entre diferentes UIs sin afectar el funcionamiento del bot, lo que facilita su adaptación según las necesidades del usuario, incluso después de su implementación. Un ejemplo es el bot SAM, que comenzó con una interfaz de navegador y luego cambió a Slack para una gestión más eficiente del equipo (Di Prospero et al., 2017).

B) Servicios y fuentes externas: Los chatbots pueden acceder a fuentes externas para obtener datos específicos del dominio o contenido dinámico, mejorando su interacción y aumentando el compromiso del usuario. Por ejemplo, un chatbot puede obtener información adicional sobre servicios universitarios o sistemas en la nube mediante servicios web REST. Esto permite que los bots proporcionen respuestas más completas y actualizadas, incluso si la información no está disponible en su base de conocimiento predefinida (Di Prospero et al., 2017).

C) El procesamiento de personalidad en un chatbot utiliza servicios de análisis como el Tone Analyzer y el Natural Language Classifier, que aplican técnicas de Procesamiento de Lenguaje Natural (NLP) para adaptar las respuestas según el tono y la intención del usuario. Estos servicios permiten que el sistema detecte el tono emocional del usuario y ajuste las respuestas para que sean más empáticas y precisas. Además, el NLP facilita la comprensión de las intenciones del usuario, lo que mejora la efectividad del chatbot al ofrecer respuestas más relevantes. A medida que el chatbot evoluciona, es posible agregar más servicios a través de plataformas como Node-Red, lo que incrementa la adaptabilidad del sistema, permitiéndole integrarse con otros servicios, como el Cloud Automation Manager, para escalar y gestionar sistemas en la nube (Di Prospero et al., 2017).

Figura 2

Arquitectura Referencial de un Chatbot



Nota. La arquitectura de un chatbot integra una interfaz de usuario, un núcleo de procesamiento con módulos de conversación, análisis de tono y clasificación del lenguaje, y servicios externos para la obtención de datos o integración en la nube. Adaptado de Di Prospero et al. (2017).

2.2.3 Errores en Respuestas de un Chatbot

A) Malentendidos. Uno de los errores más comunes en las interacciones con chatbots es el malentendido de la intención del usuario. Esto puede ocurrir debido a diversos factores, como la complejidad del lenguaje, el uso de jerga, errores tipográficos o consultas ambiguas. Cuando un chatbot no interpreta correctamente

la solicitud del usuario, puede ofrecer respuestas irrelevantes o fuera de lugar, lo que lleva a la frustración y la ineficiencia (Izadi & Forouzanfar, 2024).

B) Respuestas repetitivas. Los chatbots con capacidades limitadas de generación de respuestas pueden quedar atrapados en un ciclo repetitivo, ofreciendo las mismas respuestas una y otra vez, sin importar la entrada del usuario. Esto indica una falta de flexibilidad y puede hacer que la interacción se vuelva rápidamente monótona y frustrante para el usuario. Por ejemplo, un chatbot que repite continuamente “Lo siento, no entiendo” muestra que no puede adaptar sus respuestas (Izadi & Forouzanfar, 2024).

C) Falta de personalización. Muchos chatbots no logran adaptar sus interacciones a usuarios individuales. Esto significa que ofrecen respuestas genéricas, de talla única, que no consideran las necesidades específicas, preferencias o el historial de interacción del usuario. Esta falta de personalización puede hacer que el chatbot se sienta robótico e impersonal, lo que conduce a una experiencia de usuario menos atractiva. Por ejemplo, si un chatbot no recuerda una compra o problema anterior del usuario, no podrá ofrecer una solución útil y contextualizada (Izadi & Forouzanfar, 2024).

D) Limitaciones del lenguaje. Los chatbots a menudo tienen limitaciones en su comprensión y capacidad de generación de lenguaje. Pueden estar diseñados principalmente para funcionar en un solo idioma, lo que les impide manejar conversaciones multilingües con fluidez. Además, pueden tener dificultades con el lenguaje matizado, malinterpretando el sarcasmo, el humor o el lenguaje figurado. Esto puede llevar a malentendidos y dificultar la capacidad del chatbot para comunicarse de manera efectiva (Izadi & Forouzanfar, 2024).

2.3. Natural Language Processing (NLP)

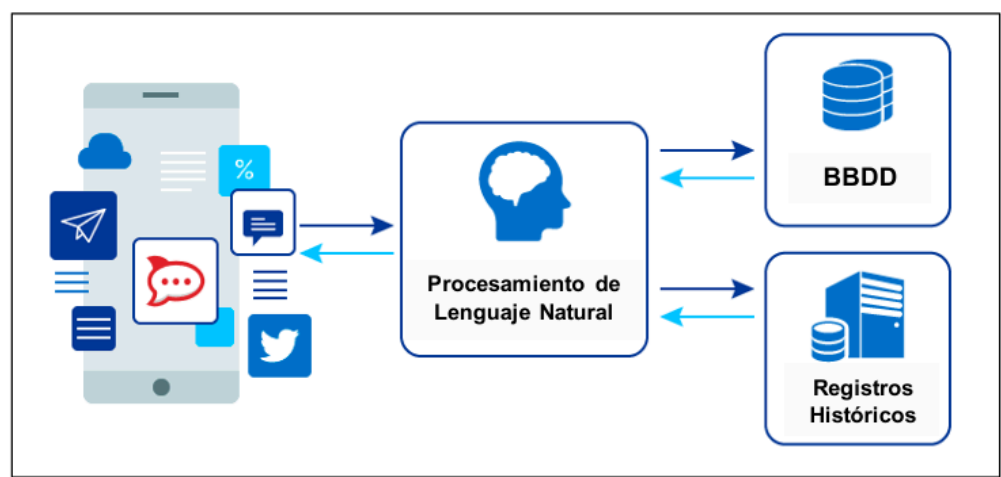
2.3.1 Definición y Aplicaciones de NLP

El procesamiento de lenguaje natural (NLP) hace referencia a la capacidad de las máquinas para comprender, interpretar y generar el lenguaje humano de una manera similar a como lo haría una persona. Este campo se basa en diversos algoritmos y técnicas que permiten a las computadoras procesar distintos tipos de lenguaje, ya sea escrito, hablado o incluso gestual. Dentro del NLP se incluyen tareas como la extracción de información, el análisis de emociones, la traducción automática y la generación de respuestas a preguntas. Su principal propósito es facilitar una comunicación fluida entre humanos y máquinas, permitiendo su interacción en múltiples contextos y aplicaciones (Chowdhary, 2020).

Por otro lado, el NLP ha avanzado significativamente gracias al uso de técnicas de aprendizaje automático y el análisis de grandes volúmenes de datos. Esta combinación ha permitido la creación de modelos y algoritmos más avanzados, mejorando considerablemente la eficiencia del NLP. A medida que aumente la disponibilidad y calidad de los datos, se anticipa que el NLP seguirá evolucionando, promoviendo una comunicación más efectiva y natural entre las máquinas y los seres humanos (Singh, 2019).

Figura 3

Diagrama de flujo del Procesamiento de Lenguaje Natural



Nota. El NLP permite que los sistemas comprendan e interpreten el lenguaje humano mediante el uso de algoritmos y bases de datos que procesan información textual o verbal para generar respuestas coherentes. Elaboración propia basada en Chowdhary (2020) y Singh (2019).

Fuente: ChatCompose (2022)

2.3.2 Conceptos Claves en NLP

Tabla 2: Conceptos Clave en NLP

Técnica de PLN de Procesamiento de Lenguaje Natural	Descripción
Tokenización	Proceso de dividir el texto en unidades más pequeñas (tokens), como palabras o oraciones.
Etiquetado de Partes del Discurso	Asignar categorías gramaticales (por ejemplo, sustantivo, verbo) a las palabras en una oración.

Reconocimiento de Entidades Nombradas	Identificación y clasificación de entidades nombradas (por ejemplo, nombres, fechas, ubicaciones) en el texto.
Análisis de Sentimiento	Determinar el tono emocional o actitud expresada en el texto (por ejemplo, positivo, negativo, neutral).

A) Tokenización

La tokenización es el proceso de dividir un texto en unidades más pequeñas, como palabras u oraciones, conocidas como tokens. Este proceso es esencial para muchas tareas de NLP (Procesamiento de Lenguaje Natural), ya que ayuda a las computadoras a entender la estructura y el significado del texto (Manning et al., 2014).

Por ejemplo, en la oración "Me encanta el procesamiento de lenguaje natural," la tokenización dividiría la oración en tokens como "Me," "encanta," "el," "procesamiento," "de," "lenguaje" y "natural" (Patra & Kumar, 2020).

B) Etiquetado de Partes del Discurso

El etiquetado de partes del discurso es el proceso de asignar una categoría gramatical (como sustantivo, verbo o adjetivo) a cada palabra en una oración. Esta información es crucial para comprender la estructura sintáctica de la oración y se utiliza en muchas aplicaciones de NLP, como la traducción automática y la recuperación de información (Jurafsky & Martin, 2019).

C) Reconocimiento de Entidades Nombradas (NER)

El Reconocimiento de Entidades Nombradas (NER) es el proceso de identificar y clasificar entidades nombradas en un texto, como nombres de personas, organizaciones, ubicaciones, fechas, entre otros. El NER es una tarea importante en la extracción de información y se utiliza en diversas aplicaciones, incluyendo motores de búsqueda y sistemas de preguntas y respuestas (Jurafsky & Martin, 2019).

D) Análisis de Sentimientos

El análisis de sentimientos es el proceso de determinar el tono emocional o la actitud expresada en un texto. Implica clasificar el texto como positivo, negativo o neutral y se utiliza en aplicaciones como el monitoreo de redes sociales y el análisis de retroalimentación de clientes (Liu, 2012).

2.3.3 Técnicas de NLP en Chatbots


El procesamiento del lenguaje natural (NLP) constituye el núcleo de los sistemas de chatbots modernos, ya que permite a las máquinas interpretar, analizar y responder de forma coherente a la comunicación humana. Las técnicas más utilizadas en el desarrollo de chatbots incluyen el pattern matching, el parsing, el enfoque basado en reglas (Rule-based approach) y el aprendizaje profundo (deep learning), las cuales posibilitan que los chatbots comprendan la estructura gramatical, generen respuestas adecuadas y aprendan continuamente del intercambio con los usuarios. Estas técnicas han permitido que los chatbots evolucionen desde simples programas basados en reglas hasta asistentes inteligentes capaces de reconocer entidades, emociones y contextos conversacionales, mejorando la interacción entre humanos y máquinas (Abdulla et al., 2022).

A) RBA(Rule-Based Approaches)

Los Rule-Based Approaches en NLP implican el uso de reglas y patrones predefinidos para procesar y comprender el texto. Aunque estos enfoques pueden ser efectivos para tareas simples, a menudo carecen de la flexibilidad y adaptabilidad necesarias para tareas más complejas de comprensión del lenguaje (Jurafsky & Martin, 2019).

Figura 4

Pasos en el RBA



Nota. Los enfoques basados en reglas aplican un proceso iterativo de creación, aplicación, procesamiento y refinamiento de reglas lingüísticas para analizar el texto. Adaptado de Jurafsky y Martin (2019).

B) Deep Learning

El aprendizaje profundo (Deep Learning) ha emergido como una de las tecnologías más prometedoras en la investigación de resultados de salud mental, principalmente debido a su capacidad para procesar grandes volúmenes de datos no estructurados y extraer patrones complejos de manera eficiente. En el contexto de la salud mental, el DL se utiliza para la detección temprana y el diagnóstico de trastornos como la depresión, mediante el análisis de datos clínicos, imágenes cerebrales, y expresiones vocales y visuales. Modelos como las redes neuronales convolucionales (CNN) y las redes neuronales recurrentes (RNN) han demostrado un rendimiento sobresaliente en tareas de

clasificación, predicción de riesgo y pronóstico de enfermedades mentales (Su et al., 2020).

C) Machine Learning

Machine Learning (ML) es un subcampo de la inteligencia artificial que se enfoca en diseñar sistemas capaces de aprender de los datos. A través de la identificación de patrones en los datos, estos sistemas pueden hacer predicciones, tomar decisiones y adaptarse a nuevas situaciones sin necesidad de intervención humana directa. El aprendizaje en ML se lleva a cabo mediante algoritmos que procesan grandes volúmenes de datos, ajustando sus parámetros a medida que el sistema interactúa con más información, lo que le permite mejorar su rendimiento con el tiempo" (Razzaq & Shah, 2025)

Tabla 3

Diferencias entre Machine Learning y Deep Learning

FACTORES CLAVE DE DIFERENCIACIÓN ENTRE DL Y ML		
MACHINE LEARNING	FACTORES	DEEP LEARNING
Extracción Manual	Enfoque de Resolución de problemas	Intervención humana mínima
Aprendizaje supervisado y reforzado	Métodos de entrenamiento	Autoencoders y Redes Generativas Antagónicas
Diversos modelos	Complejidad de Algoritmos	Interconecta Neuronas
Se apoya de Data Estructurada	Interpretabilidad	Aprovecha Redes Neuronales Artificiales
Distribuida a través de un Server Cluster	Infraestructura y Data	Depende de Datasets más grandes

Fuente: Elaboración propia

2.4. Arquitectura y Diseño del Sistema Experto Conversacional

2.4.1 Bases de Conocimiento y Reglas de Inferencia

A) Base de Conocimiento

La base de conocimiento es el elemento fundamental de cualquier sistema experto, sirviendo como el repositorio de información específica del dominio, hechos y reglas. Esta encapsula la experiencia necesaria para resolver problemas dentro de un área específica, asegurando que el sistema pueda emular los procesos de toma de decisiones humanos. Una base de conocimiento robusta permite consistencia, precisión y escalabilidad en la resolución de problemas complejos, haciéndola indispensable para aplicaciones que van desde el diagnóstico hasta la modelización predictiva (Puppe, 2012).

B) Adquisición de Conocimiento:

a) Entrada Manual por Expertos: Los expertos en el dominio proporcionan conocimiento estructurado basado en su experiencia y comprensión del campo.

b) Técnicas Automatizadas: Herramientas como el procesamiento de lenguaje natural (NLP) y la minería de datos se utilizan para extraer y formalizar conocimiento de fuentes de datos no estructurados como textos o bases de datos (Gómez & Segami, 1990; Chiu et al., 2009).

c) Enfoques Colaborativos: Los sistemas expertos integran cada vez más retroalimentación de múltiples expertos para refinar y validar la base de conocimiento.

C) Estructuración del Conocimiento

a) Conocimiento Declarativo: Hechos y relaciones, a menudo representados como reglas "IF-THEN", que garantizan lógica sencilla e interpretable (Reichgelt & Van Harmelen, 1984).

b) Conocimiento Procedimental: Codifica secuencias de acciones o algoritmos para abordar tareas específicas de resolución de problemas, mejorando la capacidad del sistema para manejar escenarios dinámicos.

c) Modelos Híbridos: Combinan métodos simbólicos y estadísticos para capturar tanto el conocimiento explícito como implícito, permitiendo una mayor flexibilidad y precisión en los procesos de razonamiento (Sahin et al., 2012).

D) Procesos de Razonamiento Lógico

El mecanismo de inferencia es el motor de un sistema experto, permitiéndole llegar a conclusiones mediante la aplicación de algoritmos de razonamiento a la base de conocimiento. Imita los procesos cognitivos humanos al examinar los datos disponibles y deducir conclusiones accionables. Los enfoques clave incluyen:

a) Razonamiento Deductivo: Aplicar reglas generales a casos específicos para llegar a conclusiones.

b) Razonamiento Inductivo: Derivar principios generales de observaciones o datos específicos.

c) Manejo de la Incertidumbre: Utilizar lógica probabilística y difusa para acomodar información incompleta o ambigua (Zhu et al., 2011).

d) Encadenamiento Hacia Adelante (Forward Chaining): Comienza con hechos disponibles y aplica reglas secuencialmente para derivar conclusiones. Es más adecuado para sistemas de diagnóstico, donde el objetivo es identificar resultados basados en condiciones dadas.

F) Encadenamiento Hacia Atrás (Backward Chaining):

Comienza con una hipótesis o objetivo y retrocede para verificar si las condiciones o hechos lo apoyan. Es común en sistemas enfocados en la prueba de hipótesis o planificación. La elección entre encadenamiento hacia adelante y hacia atrás depende de la naturaleza del problema y el flujo de razonamiento requerido (Puppe, 2012).

2.4.2 Adaptabilidad y Aprendizaje Continuo

A) Adaptabilidad y Adaptacion

La adaptabilidad en los sistemas expertos conversacionales es un aspecto crucial para mejorar la interacción y la personalización de las respuestas de los chatbots. Los chatbots con capacidades de adaptación pueden mejorar sus respuestas a medida que interactúan con los usuarios, ajustándose dinámicamente a nuevas situaciones y datos. Estos sistemas son capaces de aprender de sus errores y de incorporar retroalimentación para perfeccionar sus respuestas, lo que permite una evolución constante del comportamiento del chatbot. La adaptabilidad de estos sistemas también incluye la capacidad de personalizar las interacciones de acuerdo con las preferencias, el contexto y las emociones del usuario, lo que resulta en una experiencia más fluida y efectiva. Esta capacidad de ajuste continuo es esencial para aplicaciones en campos como la salud mental, donde es necesario ofrecer respuestas precisas y empáticas a lo largo del tiempo (Izadi & Forouzanfar, 2024).

B) Aprendizaje Continuo

El aprendizaje continuo en sistemas expertos conversacionales, como los chatbots, se refiere a la capacidad del sistema para aprender de manera constante y autónoma durante sus interacciones con los usuarios, sin necesidad de intervención humana para realizar reentrenamientos. Este tipo de aprendizaje permite que los chatbots

mejoren de manera progresiva a lo largo del tiempo, adaptándose a nuevos datos y situaciones que se presentan durante las conversaciones. El aprendizaje continuo no solo abarca la incorporación de nuevos hechos y expresiones lingüísticas, sino también la adaptación a las circunstancias cambiantes, lo que permite al sistema evolucionar con la experiencia y volverse cada vez más eficiente y preciso en sus respuestas. Esta capacidad de aprender mientras interactúa hace que el chatbot sea más inteligente y competente, optimizando la experiencia del usuario y aumentando la eficacia de las tareas que realiza (Mazumder & Liu, 2022).

2.4.3 Redes neuronales DDN, LSTM

A) Deep Deterministic Networks

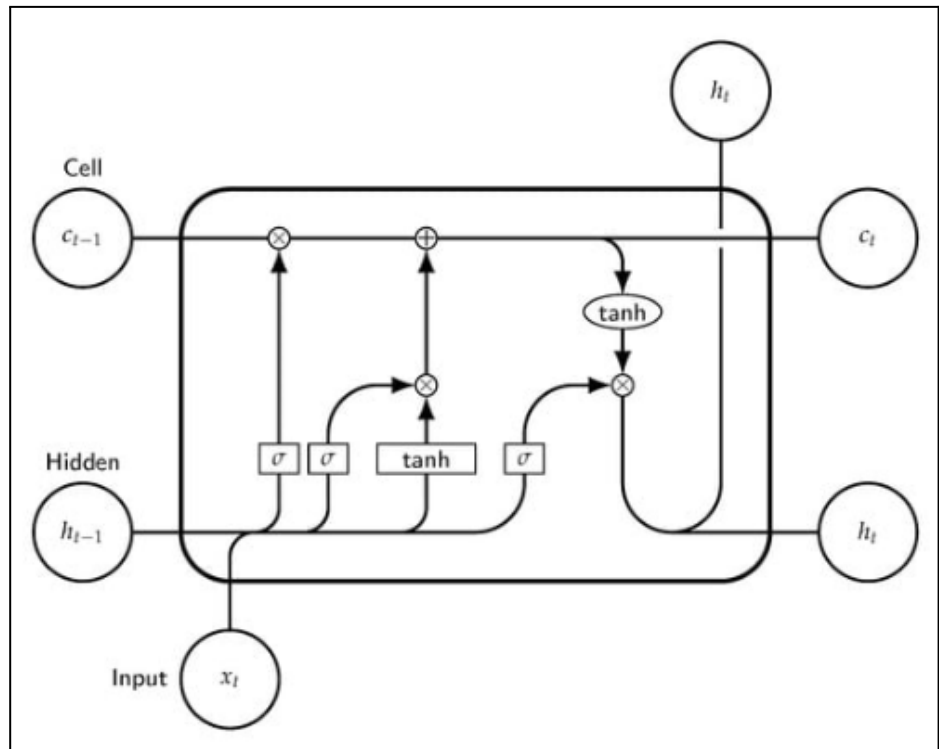
Las Deep Dependency Networks (DDN) se destacan por su capacidad para adaptarse dinámicamente a nuevas tareas mediante el aprendizaje conjunto de redes neuronales y redes de dependencias condicionales. En este enfoque, la red neuronal extrae características del dato de entrada (como una imagen o video), mientras que la red de dependencia modela las relaciones entre estas características y sus etiquetas correspondientes. Esta estructura permite que el modelo se ajuste de manera flexible a las interacciones entre las etiquetas, lo que mejora la capacidad de clasificación en tareas complejas, como la clasificación multi etiqueta. Los DDN no solo se entrenan para aprender características, sino también para inferir dependencias entre las etiquetas, mejorando su adaptabilidad a medida que se enfrentan a diferentes conjuntos de datos y tareas (Arya, Xiang, & Gogate, 2024).

B) Long Short-Term Memory

La arquitectura LSTM incluye mecanismos de memoria que permiten retener información relevante durante períodos extendidos, lo que las hace especialmente útiles para tareas que requieren mantener contexto temporal. Su capacidad de manejar dependencias a largo plazo se logra mediante sus tres puertas (entrada, olvido y salida), que regulan el flujo de información dentro de la red. Estas características hacen que las LSTM sean altamente adaptables y eficaces en tareas de procesamiento de lenguaje natural (NLP), como la traducción automática, el análisis de sentimientos y la generación de texto, entre otras aplicaciones. Este modelo ha sido fundamental para mejorar la precisión en la comprensión de secuencias de datos y para aplicaciones que requieren un análisis contextual extenso (Krichen & Mihoub, 2025).

Figura 5

Arquitectura de la celula LSTM




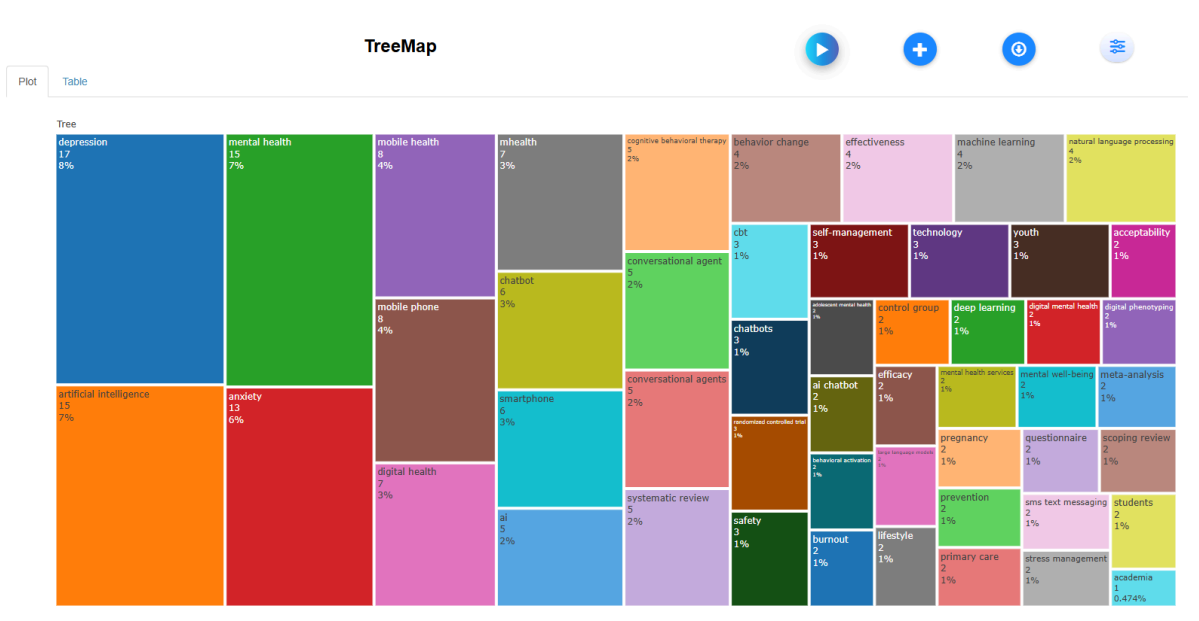
Nota. La red LSTM incluye mecanismos de memoria que permiten retener información durante largos períodos mediante sus tres puertas (entrada, olvido y salida), lo que facilita el manejo de dependencias temporales. *Adaptado de Krichen y Mihoub (2025).*

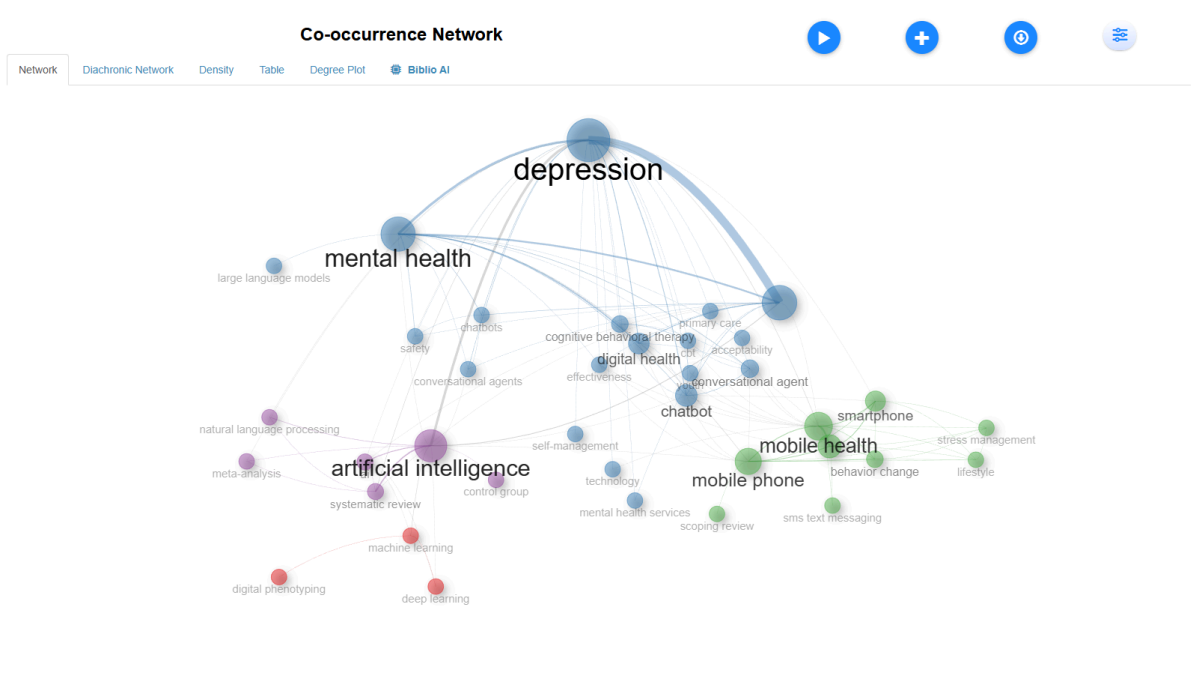
Cuestionario de salud del paciente (PHQ-9 Spanish)

Por favor, ayúdenos a brindarle la mejor atención médica respondiendo las siguientes preguntas.

Durante las últimas 2 semanas, ¿con qué frecuencia le ha molestado alguno de los siguientes problemas?	De nada	Varios Días	Más de la mitad de los días	Casi Todos los días
1. Poco interés o placer en hacer las cosas	0	1	2	3
2. Sentirse deprimido, deprimido o desesperanzado	0	1	2	3
3. Dificultad para conciliar el sueño o permanecer dormido, o dormir demasiado	0	1	2	3
4. Sentirse cansado o con poca energía	0	1	2	3
5. Falta de apetito o comer en exceso	0	1	2	3
6. Sentirse mal consigo mismo, o que es un fracaso o que se ha decepcionado a sí mismo o a su familia	0	1	2	3
7. Dificultad para concentrarse en cosas, como leer el periódico o ver la televisión	0	1	2	3
8. ¿Moverse o hablar tan despacio que otras personas podrían haberlo notado? O lo contrario: estar tan inquieto o inquieto que te has estado moviendo mucho más de lo habitual	0	1	2	3
9. Pensamientos de que estaría mejor muerto o de lastimarse de alguna manera	0	1	2	3
(Para el profesional de la salud) puntuación total de todas las respuestas de los pacientes = _____				
10. Si marcó algún problema, ¿qué tan difícil le ha dificultado hacer su trabajo, ocuparse de las cosas en casa o llevarse bien con otras personas?	No es difícil En absoluto	Algo difícil	Muy difícil	Extremadamente difícil

Desarrollado por los doctores Robert L. Spitzer, Janet B.W. Williams, Kurt Kroenke y sus colegas, con una beca educativa de Pfizer Inc. No se requiere permiso para reproducir, traducir, mostrar o distribuir.





REFERENCIAS

- Ministerio de Salud del Perú. (2024). *Establecimientos del Minsa atendieron más de 250 000 casos de depresión a lo largo del año 2024*. Gobierno del Perú. <https://www.gob.pe/institucion/minsa/noticias/1088925-establecimientos-del-minsa-atendieron-mas-de-250-000-casos-de-depresion-a-lo-largo-del-ano-2024>
- Ministerio de Salud del Perú. (2024). *La depresión es uno de los trastornos de salud mental más frecuentes en el país: el Minsa atendió 280 917 casos en 2023*. Gobierno del Perú. <https://www.gob.pe/institucion/minsa/noticias/892900-la-depresion-es-uno-de-los-trastornos-de-salud-mental-mas-frecuentes-en-el-pais>
- Méndez Sánchez, N. R. (2025). *[Tesis de pregrado, Universidad Nacional Federico Villarreal]*. Repositorio UNFV. <https://repositorio.unfv.edu.pe/handle/20.500.13084/10245>
- Diario Correo. (2024). *Depresión: preocupante aumento de casos en jóvenes universitarios*. <https://diariocorreo.pe/salud/depresion-preocupante-aumento-de-casos-en-jovenes-universitarios-noticia/>
- Denecke, K., et al. (2025). Persuasive chatbot-based interventions for depression. *Frontiers in Psychiatry*, 16, 1429304. <https://doi.org/10.3389/fpsyt.2025.1429304>
- Elahimanesh, S., Salehi, S., Zahedi Movahed, S., Alazraki, L., Hu, R., & Edalat, A. (2023). *From Words and Exercises to Wellness: Farsi Chatbot for Self-Attachment*

Technique. arXiv. <https://arxiv.org/abs/2310.09362>

- Fitzpatrick, K. K., Darcy, A., & Vierhile, M. (2017). Delivering cognitive behavior therapy to young adults with symptoms of depression and anxiety using a fully automated conversational agent (Woebot): A randomized controlled trial. *JMIR Mental Health*, 4(2), e19. <https://doi.org/10.2196/mental.7785>
- Haque, M. D. R., & Rubya, S. (2023). An overview of chatbot-based mobile mental health apps: Insights from app description and user reviews. *JMIR mHealth and uHealth*, 11, e44838. <https://doi.org/10.2196/44838>
- Klos, M. C., Wozniak, J., & Martinez, J. (2021). Artificial intelligence–based chatbot for anxiety and depression in university students: Pilot randomized controlled trial. *JMIR Formative Research*, 5(8), e20678. <https://doi.org/10.2196/20678>
- Pranckeviciene, A., Saudargiene, A., Gecaite-Stonciene, J., Liaugaudaite, V., Griskova-Bulanova, I., Simkute, D., Žukauskiene, R., & Tamosiunas, T. (2022). Validation of the Patient Health Questionnaire-9 and the Generalized Anxiety Disorder-7 in a Lithuanian student sample. *PLoS ONE*, 17(1), e0263027. <https://doi.org/10.1371/journal.pone.0263027>
- Organización Mundial de la Salud. (2023). *Depresión y otros trastornos mentales*. Recuperado de: <https://www.who.int/es/news-room/fact-sheets/detail/depression>
- WHO. (2022). *Informe global sobre la salud mental durante la pandemia de COVID-19*. Recuperado de: <https://www.who.int/es/news-room/fact-sheets/detail/depression>
- Ministerio de Salud del Perú (Minsa). (2024). *Informe Anual de Salud Mental 2024*. Recuperado de: <https://www.gob.pe/institucion/minsa/noticias/892900-la-depresion-es-uno-de-los-trastornos-de-salud-mental-mas-frecuentes-en-el-pais>
- Paricahua-Peralta, J. N., Estrada-Araoz, E. G., León-Hancco, L. B., Avilés-Puma, B., Roque-Guizada, C. E., Zevallos-Pollito, P. A., Velasquez-Giersch, L., Herrera-Osorio, A. J., & Isuiza-Perez, D. D. (2024). *Evaluación de la salud mental de los estudiantes universitarios de la Amazonía peruana: Un estudio transversal*. *Salud, Ciencia y Tecnología*, 4, 879. <https://doi.org/10.56294/saludcyt2024879>
- Zhang, W. Q. (2020). *Validity and reliability of the Patient Health Questionnaire-9 for university students* [Tesis de maestría, University of British Columbia]. University of British Columbia Repository. <https://open.library.ubc.ca/soa/cIRcle/collections/ubctheses/24/items/1.0394145>
- American Psychological Association. (s. f.). *Patient Health Questionnaire-9 (PHQ-9)*. “No permission required to reproduce, translate, display or distribute.” <https://www.apa.org/depression-guideline/patient-health-questionnaire.pdf> (APA)

- CORC – Child Outcomes Research Consortium. (s. f.). *Generalised Anxiety Disorder Assessment (GAD-7)*. “The GAD-7 is free to use... see Pfizer’s terms of use.” <https://www.corc.uk.net/outcome-measures-guidance/directory-of-outcome-measures/generalised-anxiety-disorder-assessment-gad-7/> (corc.uk.net)
- Didi Hirsch Mental Health Services. (s. f.). *GAD-7 (Generalized Anxiety Disorder)*. “No permission required to reproduce, translate, display or distribute.” <https://didihirsch.org/wp-content/uploads/GAD-7-Generalized-Anxiety-Disorder-English.pdf> (Didi Hirsch)
- Pfizer. (2010, July 21). *Pfizer to offer free public access to mental health assessment tools to improve diagnosis and patient care*. https://www.pfizer.com/news/press-release/press-release-detail/pfizer_to_offer_free_public_access_to_mental_health_assessment_tools_to_improve_diagnosis_and_patient_care (Pfizer)
- Vickybot, a Chatbot for Anxiety-Depressive Symptoms and Suicide Risk: Design and Evaluation — Computers in Biology and Medicine (ScienceDirect), 2023. <https://doi.org/10.2196/43293>
- Liu, H., Peng, H., Song, X., Xu, C., & Zhang, M. (2022). Using AI chatbots to provide self-help depression interventions for university students: A randomized trial of effectiveness. *Internet Interventions*, 27, 100495. <https://doi.org/10.1016/j.invent.2022.100495>
- Anmella, G., Sanabra, M., Primé-Tous, M., Segú, X., Caverro, M., Morilla, I., Grande, I., Ruiz, V., Mas, A., Martín-Villalba, I., Caballo, A., Esteva, J.-P., Rodríguez-Rey, A., Piazza, F., Valdesoiro, F. J., Rodríguez-Torrella, C., Espinosa, M., Virgili, G., Sorroche, C., Ruiz, A., Solanes, A., Radua, J., Also, M. A., Sant, E., Murgui, S., Sans-Corrales, M., Young, A. H., Vicens, V., Blanch, J., Caballeria, E., López-Pelayo, H., López, C., Olivé, V., Pujol, L., Quesada, S., Solé, B., Torrent, C., Martínez-Aran, A., Guarch, J., Navinés, R., Murru, A., Fico, G., de Prisco, M., Oliva, V., Amoretti, S., Pio-Carrino, C., Fernández-Canseco, M., Villegas, M., Vieta, E., & Hidalgo-Mazzei, D. (2023). Vickybot, a chatbot for anxiety-depressive symptoms and work-related burnout in primary care and health care professionals: Development, feasibility, and potential effectiveness studies. *Journal of Medical Internet Research*, 25, e43293. <https://doi.org/10.2196/43293>
- Ibrahim, S. T., Li, M., Patel, J., & Katapally, T. R. (2025). Utilizing natural language processing for precision prevention of mental health disorders among youth: A

systematic review. *Computers in Biology and Medicine*, 188, 109859. <https://doi.org/10.1016/j.combiomed.2025.109859>

- Yokotani, K., Ito, M., Ihara, N., & Shigeeda, Y. (2025). A unified protocol chatbot reduces anxiety by encouraging university students' negative emotional expressions: A randomized controlled trial. *Computers in Human Behavior Reports*, 19, 100770. <https://doi.org/10.1016/j.chbr.2025.100770>
- Guerrero, G., Avila, D., Silva, F. J. M. da, Pereira, A., & Fernández-Caballero, A. (2023). Internet-based identification of anxiety in university students using text and facial emotion analysis. *Internet Interventions*, 34, 100679. <https://doi.org/10.1016/j.invent.2023.100679>
- Villarreal, D., Reategui-Rivera, C. M., García-Serna, J., Quispe-Callo, G., Lázaro-Cruz, G., Centeno-Terrazas, G., Galvez-Arevalo, R., Escobar-Agreda, S., Dominguez-Rodriguez, A., & Finkelstein, J. (2024). Self-Administered Interventions Based on Natural Language Processing Models for Reducing Depressive and Anxiety Symptoms: Systematic Review and Meta-Analysis. *JMIR Mental Health*, 11, e59560. <https://doi.org/10.2196/59560>
- Goyal, S., Dutta, R., Dev, S., Raju, K. N., & Bhatt, M. W. (2025). MindLift: AI-powered mental health assessment for students. *Neuroscience Informatics*, 5(100208). <https://doi.org/10.1016/j.neuri.2025.100208>
- Kang, B., & Hong, M. (2025). Development and evaluation of a mental health chatbot using ChatGPT 4.0: Mixed methods user experience study with Korean users. *JMIR Medical Informatics*, 13, e63538. <https://doi.org/10.2196/63538>
- Chen, C., Lam, K. T., Yip, K. M., So, H. K., Lum, T. Y. S., Wong, I. C. K., Yam, J. C., Chui, C. S. L., & Ip, P. (2025). Comparison of an AI Chatbot With a Nurse Hotline in Reducing Anxiety and Depression Levels in the General Population: Pilot Randomized Controlled Trial. *JMIR Human Factors*, 12, e65785. <https://doi.org/10.2196/65785>
- Chowdhary, K. R. (2020). Natural Language Processing. In K. R. Chowdhary (Ed.), *Fundamentals of Artificial Intelligence* (pp. 603-649). Springer. https://doi.org/10.1007/978-81-322-3972-7_19
- Saldivia, Sandra, Aslan, Joseph, Cova, Félix, Vicente, Benjamín, Inostroza, Carolina, & Rincón, Paulina. (2019). Psychometric characteristics of the Patient Health Questionnaire (PHQ-9). *Revista médica de Chile*, 147(1), 53-60. <https://dx.doi.org/10.4067/S0034-98872019000100053>
- Piscoya-Tenorio, J. L., Heredia-Rioja, W. V., Morocho-Alburqueque, N., Zeña-Ñañez, S., Hernández-Yépez, P. J., Díaz-Vélez, C., Failoc-Rojas, V. E., & Valladares-Garrido, M. J. (2023). *Prevalence and factors associated with*

anxiety and depression in Peruvian medical students. International Journal of Environmental Research and Public Health, 20(4), 2907.
<https://doi.org/10.3390/ijerph20042907>

- Valladares-Garrido, D., Quiroga-Castañeda, P. P., Berrios-Villegas, I., Zila-Velasque, J. P., Anchay-Zuloeta, C., Chumán-Sánchez, M., Vera-Ponce, V. J., Pereira-Victorio, C. J., Failoc-Rojas, V. E., Díaz-Vélez, C., & Valladares-Garrido, M. J. (2023). Depression, anxiety, and stress in medical students in Peru: A cross-sectional study. *Frontiers in Psychiatry*, 14, 1268872. <https://doi.org/10.3389/fpsy.2023.1268872>
- Tang, Y., & He, W. (2023). Depression and academic engagement among college students: The role of sense of security and psychological impact of COVID-19. *Frontiers in Public Health*, 11, 1230142. <https://doi.org/10.3389/fpubh.2023.1230142>
- Wagner, F., Wagner, R. G., Kolanisi, U., Makuapane, L. P., Masango, M., & Gómez-Olivé, F. X. (2022). The relationship between depression symptoms and academic performance among first-year undergraduate students at a South African university: A cross-sectional study. *BMC Public Health*, 22, 2067. <https://doi.org/10.1186/s12889-022-14517-7>
- Sabzaliyev, A., & Asgarov, A. (2024). Knowledge representation in expert systems: Structure, classification, and applications. *Luminis Applied Science and Engineering*, 1(2), 31-43. <https://doi.org/10.69760/lumin.202400005>
- Mazumder, S., & Liu, B. (2022). Lifelong and continual learning dialogue systems. Springer Nature. <https://doi.org/10.1007/978-3-030-60096-9>
- Izadi, S., & Forouzanfar, M. (2024). Error correction and adaptation in conversational AI: A review of techniques and applications in chatbots. *AI*, 5, 803–841. <https://doi.org/10.3390/ai5020041>
- Pfizer. (2022, March 15). *Pfizer to offer free public access to mental health assessment tools to improve diagnosis and patient care*. Pfizer Inc. https://www.pfizer.com/news/press-release/press-release-detail/pfizer_to_offer_free_public_access_to_mental_health_assessment_tools_to_improve_diagnosis_and_patient_care
- Di Prospero, A., Norouzi, N., Fokaefs, M., & Litoiu, M. (2017). Chatbots as assistants: An architectural framework. *Proceedings of CASCAN 2017*. <https://marinlitoiu.info.yorku.ca/files/2017/11/chatbots-assistants-architectural-2.pdf?x59707>

